

UNIVERSIDADE FEDERAL DE RONDÔNIA
PROGRAMA INSTITUCIONAL DE BOLSAS
EM INICIAÇÃO CIENTÍFICA - PIBIC

RELATÓRIO FINAL - CICLO 2023/2024

PLANO DE TRABALHO

AUXÍLIO AO DIAGNÓSTICO DE FRATURAS POR FRAGILIDADE
ÓSSEA LOMBAR USANDO APRENDIZADO DE MÁQUINA:
ANÁLISE COMPARATIVA ENTRE AS PONDERAÇÕES T1 E
GRADIENTE ECO DE RESSONÂNCIA MAGNÉTICA

Discente bolsista: Gabrielly Cristine Araújo Rodrigues (Cota: PIBIC-CNPq)

Orientador: Prof. Dr. Jonathan da Silva Ramos

Projeto de Pesquisa: PVC1170-2024-Auxílio ao diagnóstico de fraturas por fragilidade óssea lombar usando aprendizado de máquina

PORTO VELHO-RO
2024

Resumo

Este estudo investiga a eficácia de métodos diagnósticos de fraturas lombares decorrentes de osteoporose e osteopenia. Essas técnicas têm mostrado potencial na diferenciação de corpos vertebrais com e sem fraturas. O objetivo é comparar diferentes métodos de segmentação de imagens para identificar suas vantagens e limitações, visando a seleção de técnicas mais adequadas para aplicações em diagnósticos por computador. A segmentação manual de regiões de interesse, como corpos vertebrais, é demorada e trabalhosa, especialmente em grandes conjuntos de dados, destacando a necessidade de ferramentas semi-automáticas com mínima intervenção manual para avançar na análise de fraturas.

Palavras-chave: Inteligência Artificial, Ressonância Magnética, Aprendizado de Máquina.

Resumo

This study evaluates the effectiveness of methods for identifying lumbar fractures associated with osteoporosis and osteopenia. The investigated techniques show potential in differentiating between vertebral bodies with and without fractures. The objective is to compare various image segmentation methods, identifying their advantages and limitations, to select the most suitable techniques for computer-aided diagnosis. Manual segmentation of regions of interest, such as vertebral bodies, is a time-consuming and labor-intensive process, especially in large datasets, highlighting the need for semi-automatic tools that require minimal manual intervention to enhance fracture analysis. **Keyword:** Magnetic Resonance Imaging, Machine Learning, Artificial Intelligence.

SUMÁRIO

1	INTRODUÇÃO	2
2	MATERIAIS E MÉTODOS	3
2.0.1	Métricas Utilizadas	3
2.0.2	Ferramentas Utilizadas	4
2.0.3	Algoritmos de Segmentação	4
3	RESULTADOS	5
4	CONCLUSÃO	8
	REFERÊNCIAS	9

1 INTRODUÇÃO

A fragilidade óssea lombar é uma condição que pode resultar em fraturas vertebrais, representando uma preocupação significativa para a saúde pública devido ao seu impacto na qualidade de vida dos pacientes. Fraturas por fragilidade vertebral, geralmente na coluna lombar (do inglês, Vertebral Fragility Fractures - VFF), frequentemente associadas a condições como osteoporose e osteopenia, são comuns entre indivíduos acima dos cinquenta anos, especialmente mulheres. Estima-se que aproximadamente 60% das mulheres e 20% dos homens nesta faixa etária sofrerão algum tipo de VFF ao longo de suas vidas. Essas fraturas podem causar dor crônica, perda de mobilidade, isolamento social e depressão, enfatizando a necessidade de diagnósticos precoces e precisos para prevenir complicações graves. A ressonância magnética (RM) destaca-se como uma ferramenta de imagem não invasiva e segura, que utiliza radiação não ionizante para fornecer imagens detalhadas da coluna vertebral. Isso permite uma avaliação abrangente das estruturas ósseas e dos tecidos moles, sendo crucial para o diagnóstico de VFF. No entanto, a segmentação das imagens de RM é uma tarefa desafiadora. A segmentação manual, apesar de ser uma prática comum, é demorada e suscetível a variações entre observadores, enquanto métodos totalmente automáticos podem exigir recursos computacionais intensivos e nem sempre oferecem resultados consistentes.

Diante disso, métodos de segmentação semiautomáticos emergem como uma alternativa promissora, combinando a precisão com a eficiência operacional. Essas técnicas reduzem a carga de trabalho manual e permitem a geração de inúmeras segmentações de referência, valiosas para o treinamento de modelos de aprendizado de máquina e deep learning. Esses modelos, por sua vez, podem ser usados para segmentar automaticamente novos casos, melhorando a precisão e a velocidade do diagnóstico. Este estudo tem como objetivo principal analisar e comparar uma variedade de métodos de segmentação de imagem, incluindo abordagens tradicionais e mais recentes, no contexto da detecção de VFF em imagens de RM. A pesquisa visa identificar as técnicas mais eficazes e eficientes, proporcionando uma base sólida para a seleção e implementação de métodos de segmentação em práticas clínicas.

2 MATERIAIS E MÉTODOS

Nesta seção, são descritos os métodos e técnicas utilizados para a comparação de diferentes algoritmos de segmentação de imagens, com foco na segmentação de fraturas vertebrais por fragilidade (VFF). A pesquisa foi conduzida de maneira sistemática, fundamentada em uma revisão abrangente da literatura.

2.0.1 Métricas Utilizadas

Para avaliar a qualidade dos métodos de segmentação, foram utilizadas diversas métricas reconhecidas. A Acurácia representa a proporção de resultados corretos (verdadeiros positivos e negativos) em relação ao total de casos examinados, sendo calculada pela razão entre a soma de verdadeiros positivos e verdadeiros negativos e o total de previsões. A Área Sob a Curva (AUC) é outra métrica utilizada para avaliar o desempenho de um modelo de classificação, derivada da relação entre a Taxa de Falsos Positivos (FPR) e a soma de falsos positivos e verdadeiros negativos. A Especificidade, por sua vez, mede a proporção de verdadeiros negativos corretamente identificados pelo modelo, obtida dividindo-se verdadeiros negativos pela soma de verdadeiros negativos e falsos positivos.

O Coeficiente de Correlação de Matthews (MCC) é uma métrica que considera todos os valores da matriz de confusão para medir a qualidade de classificações binárias, especialmente em cenários com classes desbalanceadas. O MCC é calculado pela diferença entre o produto de verdadeiros positivos e verdadeiros negativos e o produto de falsos positivos e falsos negativos, dividido pela raiz quadrada do produto das somas relevantes da matriz. A Precisão mede a proporção de verdadeiros positivos entre os resultados positivos obtidos pelo modelo, sendo calculada pela razão entre verdadeiros positivos e a soma de verdadeiros positivos e falsos positivos.

Além disso, a Sensibilidade, também conhecida como Recall ou TPR, é a proporção de verdadeiros positivos corretamente identificados, obtida dividindo-se verdadeiros positivos pela soma de verdadeiros positivos e falsos negativos. A F-Measure combina precisão e sensibilidade, sendo a média harmônica dessas duas métricas. A Hausdorff Distance (HD) é utilizada para medir a distância máxima entre dois conjuntos de pontos, útil na comparação da similaridade entre formas geométricas ou contornos em segmentações. Por fim, a Diferença de Volume Absoluta (AVD) compara o volume entre segmentações automáticas e de referência, calculando-se a razão entre a diferença absoluta dos volumes

e a soma dos volumes. Essas métricas permitem uma análise abrangente da eficácia e eficiência dos métodos de segmentação avaliados.

2.0.2 Ferramentas Utilizadas

A linguagem de programação Python foi escolhida como a principal ferramenta devido à sua vasta gama de bibliotecas especializadas, como o scikit-learn, que oferece uma variedade de algoritmos eficientes para classificação, regressão e clusterização. O scikit-learn desempenhou um papel fundamental na comparação e avaliação dos modelos de classificação utilizados.

2.0.3 Algoritmos de Segmentação

O estudo utilizou diversos modelos de aprendizado profundo (deep learning), com destaque para redes neurais convolucionais, que são amplamente adequadas para aplicações médicas. Entre os algoritmos utilizados, o FastCleverSeg é uma técnica semi-automática de segmentação que minimiza a necessidade de intervenção manual significativa (RAMOS et al., 2024). Outro algoritmo, o BGGrowth (crescimento equilibrado), (RAMOS et al., 2019).

O método GrowCut também foi empregado na segmentação de corpos vertebrais, sendo comumente utilizado em imagens médicas (VEZHNEVETS; KONOUCHE, 2005). Já o FastGrowCut é uma versão mais rápida e menos precisa do GrowCut, mas amplamente utilizado na segmentação de imagens médicas devido à sua rapidez e eficiência, sendo uma escolha popular no aplicativo 3D Slicer (ZHU et al., 2014). Por fim, o CleverSeg é um algoritmo de segmentação inteligente que otimiza o processo de anotação manual, estimando a anotação interna com base na anotação externa, em contraste com métodos de última geração anteriores que requerem anotações internas e externas (HAMMERNIK et al., 2015).

3 RESULTADOS


Os resultados da avaliação dos métodos de segmentação de imagem foram analisados de maneira abrangente, com validação por meio de testes estatísticos. Inicialmente, observou-se um destaque para o desempenho do método FastCleverSeg2, que demonstrou não apenas uma elevada acurácia, mas também um tempo de execução significativamente reduzido. Essa combinação o torna uma opção robusta para aplicações que demandam alta precisão juntamente com eficiência computacional.

A análise detalhada das métricas de desempenho revelou nuances importantes entre os diferentes modelos. Embora alguns métodos tenham se sobressaído em métricas específicas, o FastCleverSeg2 destacou-se por sua consistência em diversas métricas, tornando-se uma opção versátil para uma ampla gama de cenários. Esses resultados reforçam a ideia de que a avaliação do desempenho de um modelo não deve ser feita de forma isolada, mas dentro do contexto específico de aplicação, considerando tanto a precisão quanto a eficiência computacional.

Modelo	Acc.	Prec.	Spec.	Sens.	F-Mea.	AVD	AUC	MCC
FastGrowCut1	80.05	86.49	69.73	84.26	84.58	18.56	77.00	52.67
FastGrowCut2	86.58	89.56	80.26	89.13	89.10	10.47	84.69	67.95
FastCleverSeg1	84.14	87.17	71.22	89.24	87.71	14.88	80.23	61.17
FastCleverSeg2	87.52	90.23	82.43	89.63	89.72	8.94	86.03	70.41
CleverSeg1	84.74	86.94	70.20	90.66	88.28	13.96	80.43	62.40
CleverSeg2	87.62	89.82	81.04	90.33	89.85	8.83	85.69	70.50
BGrowth1	82.64	87.35	72.27	86.83	86.52	17.24	58.20	58.20
BGrowth2	87.12	89.54	80.11	89.97	89.52	9.47	85.04	69.20
GrowCut2	85.59	89.14	79.52	88.27	88.42	9.76	83.89	65.77

Tabela 1 – Resultados médios dos modelos em porcentagem (%)

Na comparação geral entre os métodos, utilizando métricas como acurácia, precisão e tempo de execução, o FastCleverSeg2 novamente obteve uma posição de destaque. Com uma acurácia média de 87,52% e um tempo de execução médio de 0,039 segundos, esse método demonstrou ser eficaz e eficiente. Por outro lado, modelos como o BGrowth1, embora tenham apresentado alta precisão em certas métricas, mostraram uma acurácia global inferior, sugerindo que, embora eficazes em alguns aspectos, esses modelos podem não ser ideais para todas as situações.




outliers no boxplot A análise dos boxplots corroborou a consistência do FastCleverSeg2 em diversas métricas, incluindo acurácia, especificidade e tempo de execução. Este modelo, em particular, atingiu uma acurácia de 87,62% e uma especificidade de 82,43%, evidenciando sua robustez. Em contrapartida, o CleverSeg2 obteve um bom desempenho

na métrica de coeficiente de correlação de Matthews, indicando que diferentes métodos podem ser mais adequados para métricas específicas, conforme as exigências da aplicação.

Ao examinar mais detalhadamente os modelos de segmentação de imagem, foi possível identificar as forças e fraquezas de cada um. O FastGrowCut1, por exemplo, mostrou boa precisão e sensibilidade, sendo eficaz na identificação de verdadeiros positivos, mas sua especificidade inferior sugere uma maior proporção de falsos positivos. Já o FastGrowCut2, com alta especificidade, destacou-se na identificação de verdadeiros negativos, mas sua sensibilidade a ruídos pode limitar sua eficácia em imagens com características anômalas. O FastCleverSeg2, equilibrando alta precisão com baixo tempo de execução, provou ser ideal para aplicações práticas. Em contraste, modelos como CleverSeg1 e BGrowth2, embora tenham demonstrado bom desempenho em métricas específicas, podem não ser tão robustos em cenários mais complexos.

Em suma, a análise realizada evidencia que cada modelo possui vantagens e limitações que devem ser cuidadosamente consideradas conforme a aplicação específica. O FastCleverSeg2 emergiu como uma escolha confiável, combinando precisão e eficiência computacional. No entanto, a escolha do método mais adequado deve levar em conta todas as métricas relevantes para garantir uma segmentação de imagem eficaz e precisa.



4 CONCLUSÃO

A partir da análise comparativa dos métodos de segmentação de imagem para a detecção de fraturas lombares, conduzida neste estudo, foi possível chegar a conclusões relevantes sobre a eficácia e as limitações de cada abordagem. A avaliação criteriosa das métricas de desempenho, como acurácia, sensibilidade, especificidade e tempo de execução, permitiu uma compreensão aprofundada do desempenho relativo de cada método.

Inicialmente, o objetivo do projeto era realizar uma análise comparativa entre as ponderações T1 e gradiente eco na detecção de fraturas lombares usando ressonância magnética. No entanto, ao longo da pesquisa, houve uma mudança de foco devido ao interesse e às demandas específicas dos parceiros envolvidos no projeto. Assim, a pesquisa direcionou-se para a análise dos métodos de segmentação de imagem como uma ferramenta crítica na detecção dessas fraturas.

Nesse novo contexto, a ressonância magnética reafirmou-se como uma ferramenta não invasiva e essencial para o diagnóstico de patologias da coluna vertebral, como fraturas lombares decorrentes de osteoporose e osteopenia. A detecção precoce dessas fraturas é vital para prevenir complicações e melhorar a qualidade de vida dos pacientes.

Quanto aos métodos de segmentação de imagem, a segmentação semiautomática mostrou-se uma abordagem promissora, pois reduz significativamente a necessidade de intervenção manual, aumentando a eficiência do processo. Métodos como FastCleverSeg2 e CleverSeg2 destacaram-se por combinar precisão elevada com eficiência computacional.

A análise detalhada dos modelos revelou características que diferenciam cada abordagem. Enquanto alguns métodos apresentaram excelente desempenho em métricas específicas, como sensibilidade ou precisão, outros demonstraram um desempenho robusto em múltiplas métricas, como foi o caso do FastCleverSeg2, que se destacou pela alta acurácia e pelo tempo de execução rápido, comprovando sua eficácia na segmentação de fraturas lombares em imagens de ressonância magnética.

Contudo, é importante destacar que a escolha do método mais adequado deve levar em consideração as particularidades da aplicação, equilibrando a precisão com a eficiência computacional. Essa decisão deve ser orientada por uma análise cuidadosa das métricas de desempenho para garantir resultados precisos e confiáveis na detecção de fraturas lombares.

Em resumo, apesar do redirecionamento do foco da pesquisa, este estudo oferece uma contribuição valiosa para a área de análise de dados médicos. Fornece uma base sólida para a seleção e implementação de técnicas de segmentação de imagem adequadas à detecção de fraturas lombares, atendendo de forma eficaz às demandas específicas da prática clínica.

REFERÊNCIAS

- HAMMERNIK, K. et al. Vertebrae segmentation in 3d ct images based on a variational framework. In: _____. *Recent Advances in Computational Methods and Clinical Applications for Spine Imaging*. Cham: Springer International Publishing, 2015. p. 227–233. ISBN 978-3-319-14148-0. Disponível em: <https://doi.org/10.1007/978-3-319-14148-0_20>.
- RAMOS, J. S. et al. Fast and accurate 3-d spine mri segmentation using fastcleverseg. *Magnetic Resonance Imaging*, v. 109, p. 134–146, 2024. ISSN 0730-725X. Disponível em: <<https://www.sciencedirect.com/science/article/pii/S0730725X24000778>>.
- RAMOS, J. S. et al. Bgrowth: an efficient approach for the segmentation of vertebral compression fractures in magnetic resonance imaging. In: *Proceedings of the 34th ACM/SIGAPP Symposium on Applied Computing*. [S.l.: s.n.], 2019. p. 220–227.
- VEZHNEVETS, V.; KONOUCINE, V. Growcut: Interactive multi-label nd image segmentation by cellular automata. In: CITESEER. *proc. of Graphicon*. [S.l.], 2005. v. 1, n. 4, p. 150–156.
- ZHU, L. et al. An effective interactive medical image segmentation method using fast growcut. In: *MICCAI workshop on interactive medical image computing*. [S.l.: s.n.], 2014.